

# **Relatório do 3º Desafio em RNA/Deep Learning Aluna: Cristiane Gea**

## **Classificação de Dígitos Manuscritos com MLP e CNN**

Data: 30/09/2025 20:34

### **1. Introdução**

Este relatório apresenta a implementação e avaliação de dois modelos de redes neurais para classificação de dígitos manuscritos do dataset MNIST: uma Rede Neural Multicamadas (MLP) e uma Rede Neural Convolucional (CNN). Foram implementados procedimentos de early stopping e taxa de aprendizado adaptativa, além da classificação de dígitos próprios.

### **2. Metodologia**

Dataset: MNIST (60.000 imagens de treino, 10.000 de teste)

Pré-processamento: Normalização para [0,1] e reshape

Callbacks: Early Stopping (paciência=10) e ReduceLROnPlateau (fator=0.5, paciência=5)

Arquitetura MLP: 2 camadas densas (512 -> 256 unidades) com ativação ReLU

Arquitetura CNN: 3 camadas convolucionais (64 -> 128 -> 128 filtros) + MaxPooling + Dropout

### **3. Resultados**

#### **3.1. Resultados MLP**

Arquitetura: 2 camadas densas (512 -> 256 unidades)

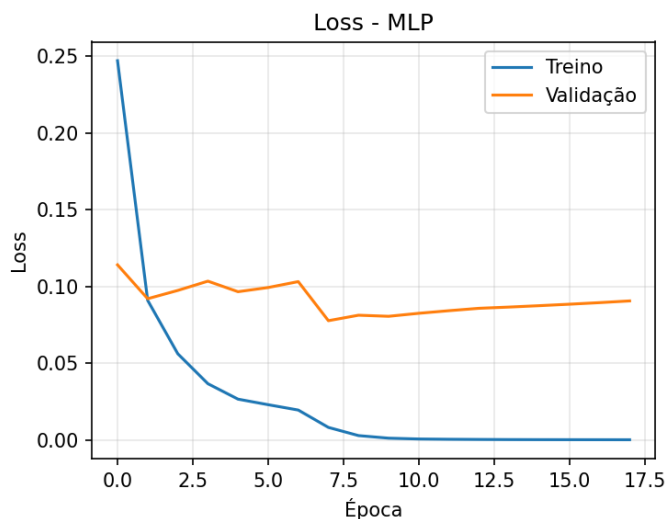
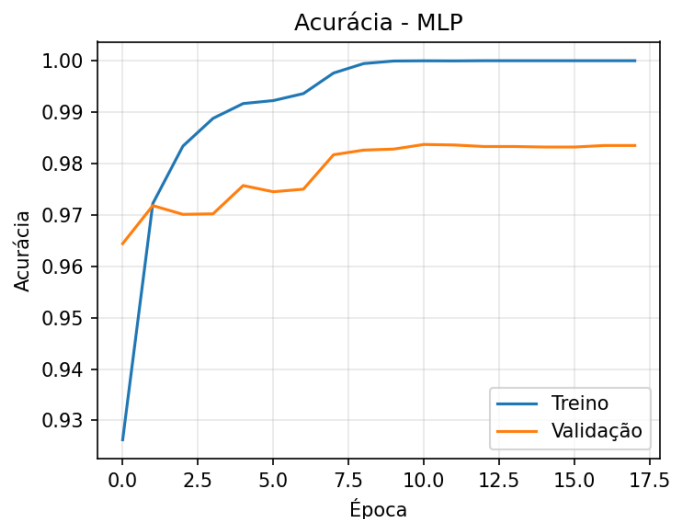
## Relatório do 3º Desafio em RNA/Deep Learning

Função de Ativação: ReLU

Otimizador: Adam

Acurácia Final: 0.9835

Épocas de treinamento: 18



### 3.2. Resultados CNN


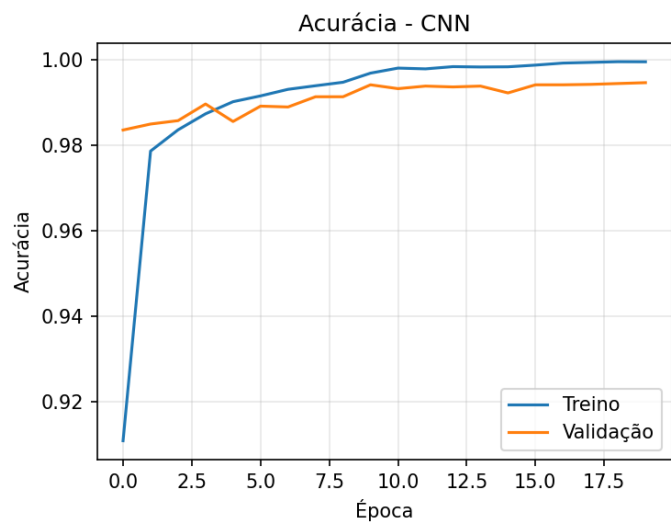
Arquitetura: 3 camadas convolucionais (64 -> 128 -> 128 filtros)

Pooling: 2 camadas MaxPooling (2x2)

Camada Densa: 128 unidades + Dropout (0.5)


Acurácia Final: 0.9945

Épocas de treinamento: 20




4. Matrizes de Confusão

MLP:



CNN:



5. Classificação de Dígitos Próprios

Dígito 1:

MLP: Classe 1 (Confiança: 0.9999)

## Relatório do 3º Desafio em RNA/Deep Learning

CNN: Classe 1 (Confiança: 1.0000)

### **Dígito 9:**

MLP: Classe 8 (Confiança: 0.9069)

CNN: Classe 9 (Confiança: 0.9876)

### 6. Análise Comparativa

Desempenho Geral:

- MLP: Acurácia = 0.9835
- CNN: Acurácia = 0.9945
- Melhoria: +1.10%

Observações:

- CNN apresentou melhor desempenho em ambas as bases de teste.
- A CNN foi mais confiante nas classificações dos dígitos próprios.
- A MLP ainda apresenta bom desempenho, mas sem capturar padrões espaciais.

### 7. Vantagens e Desvantagens das CNNs

VANTAGENS:

- Captura características hierárquicas e espaciais
- Invariância a translações, rotações e escalas
- Melhor performance em tarefas visuais
- Menos parâmetros que MLPs equivalentes
- Detectam padrões locais eficientemente

DESVANTAGENS:

- Computacionalmente mais intensivas
- Mais complexas de ajustar
- Requerem mais dados para treinamento
- Hiperparâmetros adicionais (filtros, pooling, etc.)
- Menos interpretáveis que MLPs simples